

4/16

第1章 序論

1.1 最初の言語

① 形式言語理論の2つの起源

- (1) Norm Chomsky ^{アフリカの言語学者} による自然言語の構造に対する厳密な特徴 (1950年代)

言語学 (文学部?)
(拡大生成理論, GB理論...)

学問に文系・理系の区別があるのは日本だけ

→ 変形文法理論

- (2) プログラミング言語 ALGOL60 に対する形式的仕様記述の開発

コンピュータサイエンス (理工学部?)

→ コンパイラ構成論

プログラミング言語論 (関数型, 論理型, オブジェクト指向型...)

日本では隔りがあるが、林区別はない

② プログラミングパラダイム (見概)

手続き型	...	プログラムは手続きだ!
関数型	...	合成関数だ!
論理型	...	定理証明だ!
オブジェクト指向型	...	オブジェクト間のメッセージ伝達の定義だ!

例 1.1 (括弧言語)

正しく対応した左括弧と右括弧の任意の列から成る集合

ex.) { (()) } ok,

() () ok → LISP
インテリジェント言語

(() ()) NG

③ 言語とは ある条件を満たす記号列の集合である

ex.) 英語とは、英語を母語とする人が文法的と認めるという条件を満たす a, b, c, ..., z からなる記号列の集合である。

括弧言語の帰納的定義

(()) は (A) と書けるので
(1) "A" (2) 対応した括弧

(1) 記号列 () は対応した括弧である

(2) 記号列 A が対応した括弧ならば (A) (対応した括弧)

(3) 記号列 A, B

AB

((())) (3)
(2) A (1) (1) B (2)

④ 括弧に閉じる形式文法 = "プログラマ" の集合

- (1) $S \leftrightarrow ()$
- (2) $S \leftrightarrow (S)$
- (3) $S \leftrightarrow SS$

「プログラマ」と呼ぶ

(書き換え規則の集合)

$$S \xRightarrow{(1)} SS \xRightarrow{(2)} (S)S \xRightarrow{(1)} (())()$$

4/23 続

(1) → 『Sを()で置き換えて新しい記号列を作っても良い』
という意味

$$\begin{aligned} S &\xRightarrow{(3)} SS \xRightarrow{(2)} (S)S \xRightarrow{(1)} (())S \\ &\xRightarrow{(2)} (())(S) \xRightarrow{(3)} (())(SS) \\ &\xRightarrow{(1)} (())(())S \xRightarrow{(1)} (())((X)) \end{aligned}$$

導出過程 //

→ $S \Rightarrow (())X((X))$ と表記する

『Sはいくつかのステップのうちに $(())X((X))$ を導出する』

• vとwを任意の記号列とするとき、
記法 $v \Rightarrow w$ を
『vはwを直接導出する』と読む

④ 文法には2種類の記号が現れる


- 1) 導出には表れるが、最終的な記号列には現れない記号 ex.) S
- 2) 生成しようとしている記号列のアルファベットを構成する記号
ex.) '(', ')', 最終的な記号列

- 1) ⇒ 非終端記号... 書き換えられる記号
- 2) ⇒ 終端記号... 書き換えられない記号

英語とかのアルファベット, () などのプログラミング言語とかのキーボードで打てる文字

④ プログラミング言語の文法記法について用いられる記法

BNF (Backus - Naur - Form)



- 非終端記号 <> で囲む
- → は ::= で表記する

ツールが欲しい 日本人の人才
= 形態素解析, 自然言語処理が出来る技術者

(P4) 1.2 文法と言語

X : 記号の空でない有限集合
アルファベット と呼ぶ。

ex) (1) 英語の場合

$X = \{a, b, c, \dots, x, y, z\}$

(2) 二進法表現の場合

$X = \{0, 1\}$

今後何度も出てくる。

X^*

X 上の有限長の記号列全体から
成る集合 (無限集合)

ex) $X^* = \{0, 1\}$ の場合

$X^* = \{\lambda, 0, 1, 00, 01, 10, 11, 000, 001, \dots\}$

λ : 空列... 長さ0の記号列。

$\{\lambda, 0, 1, 00, 01, 10, 11, 000, 001, \dots\}$
長さ0 長さ1 長さ2 長さ3
 $2^2 = 4$ 通り $2^3 = 8$ 通り

X 上の言語 L とは X^* 上の任意の
部分集合のことという

ex) $X = \{ (,) \}$ のとき

括弧言語 M は $M \subseteq \{ (,) \}^*$

(であるから) 確かに言語である

$M = \{ (), (X), ((X)), \dots \}$

$X \dots (,), ((, ((, \dots$

→ not 括弧言語。

$X \in V$
アスタリク
に
入ることは
ない。

言語 L の各記号列 w は

有限の長さ $|w| \in \mathbb{N}$

空列の場合は $|\lambda| = 0$ である

$w = x_1, x_2, x_3, \dots, x_n$ のとき (ただし
各 j に対し $x_j \in X$ のとき) $|w| = n$ である

→ つまり、長さ $|w|$ とは、 w に含まれる記号の
個数 (文字数) である。

$X^+ = X^* - \{\lambda\}$ ← X 上の長さ1以上の
記号列の集合。

ex.) $X = \{0, 1\}$ のとき

$X^* = \{\lambda, 0, 1, 00, 01, 10, 11, 000, \dots\}$

$X^+ = \{0, 1, 00, 01, 10, 11, 000, \dots\}$

$w = x_1, x_2, \dots, x_n, w' = x'_1, x'_2, \dots, x'_m$ のとき
 w と w' を 接続 すると 記号列

$ww' = x_1, x_2, \dots, x_n, x'_1, x'_2, \dots, x'_m$

が得られる ($|w| = n, |w'| = m$ である)

接続 ... 記号列を並べて結合する演算

ex) $w = \text{news}, w' = \text{paper}$ のとき
 $ww' = \text{newspaper}$ となる

定義 1.2.1

句構造文法 G とは、4項組 (X, V, S, P) ^{こうき}
のことという。ただし X と V は 交わりを
持たないアルファベット であり

(1) X は文法の 終端アルファベット であり、

(2) V は文法の 非終端 であり、

→ 続

(3) S は文法の開始記号であり さらに

(4) P は文法のプロダクションの集合である。

$(v, w) \in P$ ならば $v \rightarrow w$ と記す
 \downarrow \downarrow
 長さ1以上 長さ0以上

P は組 (v, w) の集合である ただし v は少なくとも1つの非終端記号を含む $(X \cup V)$ 上の記号列であり w は $(X \cup V)^*$ の任意の元である

$X = \{ (,) \}, V = \{ S \}$, S は開始記号
 $P = \{ (S, ()), (S, (S)), (S, SS) \}$

$\hookrightarrow S \rightarrow (S)$ と記した (略式)

ex) (括弧言語の場合) 略式

$P = \{ S \rightarrow (), S \rightarrow (S), S \rightarrow SS \}$

$P = \{ (S, ()), (S, (S)), (S, SS) \}$
 \downarrow
 $v \quad w$ 正式

$X = \{ (,) \}, V = \{ S \}$

S は開始記号であった

④ $y = z$ であるか、又は、記号列の並び w_1, w_2, \dots, w_n が存在して、
 $w_1 = y$ かつ $w_n = z$ であり、かつすべての i に対して w_i は w_{i+1} と直接導出可能とき、 y は z と導出可能という。

$w_i \Rightarrow w_{i+1}$

$y = w_1 \Rightarrow w_2 \Rightarrow \dots \Rightarrow w_i \Rightarrow w_{i+1} \Rightarrow \dots \Rightarrow w_n$
 \downarrow
 = 導出可能の場合

5/7
 (PS)

定義 1.2.2

G を文法とし y と z を $X \cup V$ に属する有限長の記号列とする

すべての i に対して $w_i \Rightarrow w_{i+1}$ が成立
 $\left\{ \begin{array}{l} i=1 \text{ のとき } w_1 \Rightarrow w_2 \\ i=2 \text{ のとき } w_2 \Rightarrow w_3 \\ \vdots \\ i=n-1 \text{ のとき } w_{n-1} \Rightarrow w_n \end{array} \right.$

y の中に現われているあるプロダクションの1つの左辺をその右辺で置き換えることにより y から z が得られるとき $y \Rightarrow z$ と書き y は z と直接導出可能という

$y \xRightarrow{*} z$... プロダクションを0回以上有限回適用して y から z を導出可能とできる

例えば $v \rightarrow w$ が G のプロダクションであり、
 $y = puv$, $z = pw$ と書けるとき $y \Rightarrow z$ である

G を開始記号 S をもつ文法とする。
 G によって生成される言語 $L(G)$ は

$$L(G) = \{ w \mid w \in X^* \text{ かつ } S \Rightarrow w \}$$

と定義される

$$L(G) = \{ w \mid w \in X^* \text{ かつ } S \Rightarrow w \}$$

w は長さ 0 以上の終端記号列

w は開始記号 S から始めてプロダクションを 0 回以上有限回適用することによって導出できる。

例 1.2.4.

$$V = \{ S \}, X = \{ a, b \}$$

$$P = \{ S \rightarrow aSb, S \rightarrow ab \}$$

S : 開始記号

$$L(G) = \{ a^n b^n \mid n > 0 \}$$

$$a^n = \underbrace{aa \cdots a}_{n \text{ 回}}$$

$$S \Rightarrow ab$$

$$S \Rightarrow aSb \Rightarrow aabb$$

$$S \Rightarrow aSb \Rightarrow aaSbb \Rightarrow aaabbb$$

(p7) 例 1.2.5

(*)

$$S \rightarrow aSa \mid bSb \mid a \mid b \mid \lambda$$

● 通常の文法の記法

空列
(長さ 0 の記号列)

(例 1.2.4)

$$V = \{ S \}, X = \{ a, b \}$$

$$P = \{ S \rightarrow aSb, S \rightarrow ab \}$$

非終端記号
大文字

終端記号
小文字

で表記

文法の略記法

単にプロダクションを並べて表記

$$S \rightarrow aSb \mid ab$$

正式に書くと

$$V = \{ S \}, X = \{ a, b \}$$

$$P = \{ S \rightarrow aSa, S \rightarrow bSb, S \rightarrow a, S \rightarrow b, S \rightarrow \lambda \}$$

④ この文法 (*) は生成する言語は?

$$S \Rightarrow \lambda$$

$$S \Rightarrow a$$

$$S \Rightarrow b$$

$$S \Rightarrow aSa \Rightarrow aa \quad (S \Rightarrow \lambda)$$

$$S \Rightarrow aSa \Rightarrow aaa \quad (S \Rightarrow a)$$

$$S \Rightarrow aSa \Rightarrow aba \quad (S \Rightarrow b)$$

$$S \Rightarrow bSb \Rightarrow bb$$

$$S \Rightarrow bSb \Rightarrow bab$$

$$S \Rightarrow bSb \Rightarrow bbb$$

$$S \Rightarrow aSa \Rightarrow abSba \Rightarrow ababba$$

$$\Rightarrow ababababba$$

S (があらたに) を中心として、左右対称

④ アルファベット $\{a, b\}$ 上の回文を生成する文法

(参考) 通常の回文

日本語: シンバシ, ワヤブヤケツ, 山本山

英語: Madam, I'm Adam

例 12.6

$V = \{S, A, B\}$, $X = \{0, 1\}$

$S \rightarrow 0B \mid 1A$

$A \rightarrow 0 \mid 0S \mid 1AA$

$B \rightarrow 1 \mid 1S \mid 0BB$

ⓐ 開始記号: S

ⓑ 終端記号: X

ⓐ この文法が生成する言語は?

$S \Rightarrow 0B \Rightarrow 01$

$S \Rightarrow 1A \Rightarrow 10$

$S \Rightarrow 0B \Rightarrow 01S \Rightarrow 011A \Rightarrow 0110$

$S \Rightarrow 0B \Rightarrow 00BB \Rightarrow 001B \Rightarrow 0011$

$S \Rightarrow 1A \Rightarrow 11AA \Rightarrow 110SA$

$\Rightarrow 1100BA \Rightarrow 11001A \Rightarrow 110010$

ⓑ 0と1を同数含む2進列を導出する文法

→ このことを 数学的帰納法 で証明すると...

導出される終端記号列の長さに関する帰納法

証明すべきこと

(1) 0, 1 を同数含む記号列のみを導出.


(2) 0, 1 を同数含む記号列は全てこの文法で導出できること

(1) と証明する代わりに、次の3つの命題を同時に証明.

① S から 0, 1 を同数含む記号列のみが導出可能であり.

② A から導出可能な記号列は、0 と 1 が余計に含む.

③ B から導出可能な記号列は、1 と 0 が余計に含む.



5/21

(p11)

1.3. 文脈自由言語 と 文脈依存言語

定義 1.3.1

→ 文脈自由文法

文法 G が 文脈自由 であるとは.

P の各プロダクション $[v \rightarrow w]$

において v は 1つの非終端記号 であるときという.

定義 1.3.2

文法 G は各プロダクションが次のいずれかの形のととき 文脈依存 である

(1) $yAZ \rightarrow ywZ$

(ただし $A \in V, Z \in (V \cup X)^*, w \in (V \cup X)^*$)

(2) $S \rightarrow \lambda$

(S はプロダクションの右側に表れない)

$$y \boxed{A} z \rightarrow y \boxed{w} z$$

Aの右側に y があり、右側に z がある
という文脈において、A と w と書き換えてよい。

※ ただし

- $A \in V$ (Aは非終端記号)
- $z \in (V \cup X)^*$
(zは非終端記号または終端記号からなる
長さ1以上の記号列。)

その他に ...

$S \rightarrow \lambda$ も許されている。
 $\underbrace{S}_{\text{開始記号}} \rightarrow \underbrace{\lambda}_{\text{空列}}$

複雑 ↑	4コルスキー階層	言語の複雑さの階層
	文脈依存言語 U +	X → 自然言語
	文脈自由言語 U +	X → プログラミング言語
	有限状態言語 (正則言語)	(有限オートマトン) X → 鳥の歌 (ゴキウ)

⑥ 導出過程 (0011の導出過程)

$$\begin{aligned}
 S &\Rightarrow 0B \Rightarrow 00BB \\
 &\Rightarrow 001B \\
 &\Rightarrow \boxed{0011}
 \end{aligned}$$

• 入力記号列 0011 から左の導出木を
生成する処理を 構文解析 と呼ぶ。


p13.

ある記号列が 文脈自由文法 によって
正しく導出できるならば、その導出を
次の性質をもつ 木T によって記述
することができる。

- (1) 根は開始記号 S でラベル付けされている。
- (2) 葉でない各ノードは非終端記号でラベル付けされている
- (3) 葉である各ノードは 終端記号
(λ も λ) でラベル付けされている。
- (4) ノード N が A でラベル付けされている
N が k 個の子ども N_1, N_2, \dots, N_k
をもち、それらがそれぞれの記号
 A_1, A_2, \dots, A_k でラベル付けされている
とき、文法には

$$\boxed{A \rightarrow A_1 A_2 \dots A_k} \text{ となる形の } \text{規則} \text{ が存在する}$$

⑦ 文脈自由型の導出木





ex. 同数の 0 と 1 を含む
2進列を生成する文法

$$\left. \begin{aligned}
 S &\rightarrow 0B \\
 S &\rightarrow 0BB \\
 B &\rightarrow 1
 \end{aligned} \right\}$$


のようなプログラミングを
含んでいる。

参考図。

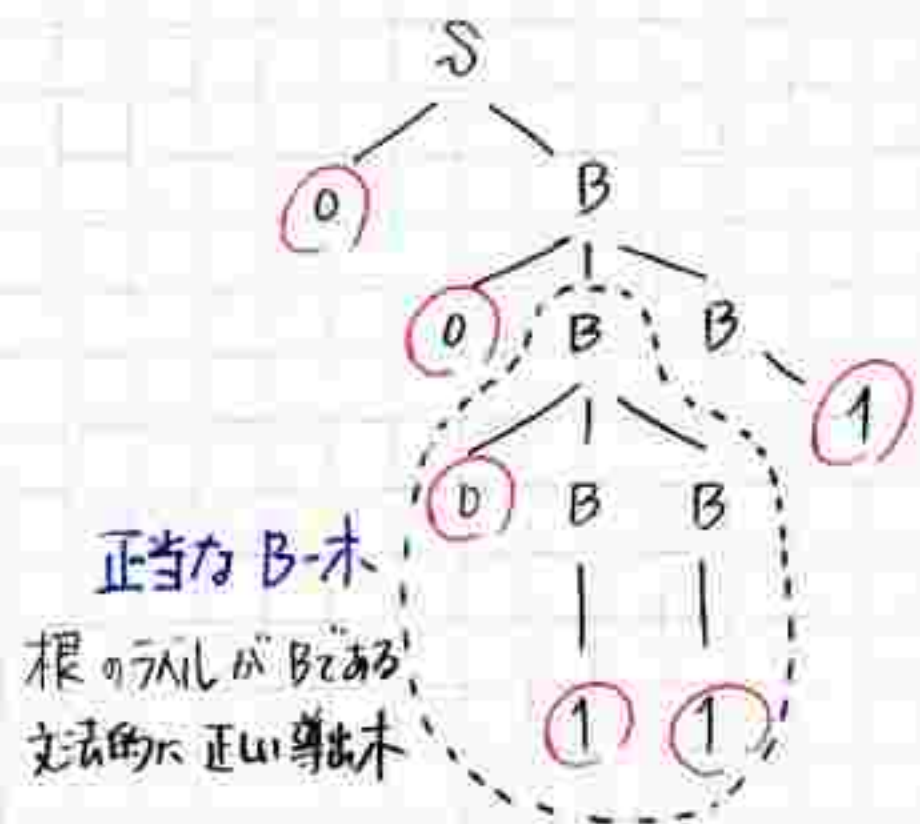


707731

記号列 0011 に対する導出木




112の長さは3.



正当为 B-木

根のラシルがBである
文法的に正しい導出木


00010111 1 封路 粵出木



- 上の数式が表現する2つの導出

$S \rightarrow 0B \rightarrow 00B \rightarrow 001B \rightarrow 0011$ (最左导出)
 $S \rightarrow 0B \rightarrow 00B \rightarrow 00B1 \rightarrow 0011$ (最右导出)

(p15) 図 1.2



記号 | u v w x y
に付与 導出

同一パス上に、
非終端記号 A が
2回現れる導出木

(p14)

刈払自由型の導出木が与えられたとき、根から葉のパスの長さとは、そのパス上の非終端の個数を定義する。
木の高さとは、その木の最長パスの長さである。

言語 $\{a^n b^n c^n \mid n > 0\}$

は、文脈自由ではない。

文脈自由文法では生成できない。

(p16) 補題 1.35 (ポンプの補題)

L を文脈自由言語とする。このとき

L のみに依存する定数 $|p|$ と $|q|$ が存在して、 $|z| \geq |p|$ かつ $|z| > |p|$ ならば、 z は以下の条件を満たすように $uvwx|y$ と書くことができる。(1) $|vwx| \leq |q|$ (2) v と x のうち高々1つが空である。(3) 全ての $i \geq 0$ に対し uv^iwx^iy は L に属する。

文脈自由言語 L

|| z

{ ..., uvwx|y, ...

..., uv²wx²y,, uv³wx³y,, uvⁱwxⁱy, ... }

v, x が膨らんでいく様子から、

"ポンプ"の補題と呼ばれる。

(p17) 例 1.36 の証明

• 背理法で証明する為に

言語 $\{a^n b^n c^n \mid n > 0\}$ が、文脈自由であるとみると、左の条件 (ポンプの補題) を満たす p, q が存在する。 $|r| > |p|$ かつ $|r| > |q|$ とし列 $|a^r b^r c^r| = z$

と置く。この列には、ポンプの補題が適用

でき、 $z = uvwx|y$ と書ける

境界

a ^r	b ^r	c ^r
----------------	----------------	----------------

u	v	w	x	y
---	---	---	---	---

部分列 vwx は $|v| + |w| + |x| \leq |q|$ かつ a, b, c の3文字が全て含まれることはない。

(1) a のブロック, b のブロック, または c のブロックのどれか1つの内側に完全に含まれるか。

(2) 1つの境界をまたぐことができるだけである

この(1), (2)の2つのどちらの場合にせよ引き延ばした列 uv^2wx^2y において a, b または c のうち少なくとも1つの記号が増加できない $uv^2wx^2y \notin L$

(1) 部分列 vwx が a, b, または c のブロックのどれか1つの内側に完全に含まれる場合

a ^r	b ^r	c ^r
----------------	----------------	----------------


u	v	w	x	y
---	---	---	---	---

b...b

 $L = \{a^n b^n c^n \mid n > 0\}$



例えば uvw が b のブロックに含まれる場合には、 uv^2wx^2y には b の個数しか増加しない

(2) 部分列 uvw が 1つの境界 (a と b の境界か、または b と c の境界とまたぐ場合) とまたぐ場合



導出木

つまり、これは構文解析をしている。



$$L = \{a^n b^n c^n \mid n \geq 0\}$$

例えば、上の状況からは uv^2wx^2y には c の個数だけ増加できない。

(問2)

① $S \rightarrow aB$	③ $B \rightarrow b$
② $B \rightarrow bA$	④ $A \rightarrow cB$

このとき、文法 G によって生成される言語を求めよ。

(p18) 例 1.3.7

言語 $\{a^k \mid k \text{ は完全平方数}\}$

(文脈自由ではない)

6/11

$$S \Rightarrow aB \Rightarrow abA \Rightarrow ababB \Rightarrow ababA \Rightarrow \dots \Rightarrow abab \dots babab$$

A. a と b が交互に表れる文法。
 ab は連続する文法。

(問1) 次の文脈自由文法を考える。

導出は
開始
記号から。
 $S \rightarrow aAB$
 $A \rightarrow Bba$
 $B \rightarrow bB, B \rightarrow C$

このとき終端記号列


$acbabbc$

に対する導出木を記す

$$S \Rightarrow aAB \Rightarrow a\bar{B}ba\bar{B} \Rightarrow acbab\bar{B} \Rightarrow acbabbc$$

} 最左導出

① 小さな具体例で試す。



①
↓
導出の開始の
ところのみ

記号の列の長さを
伸ばす。

③
↓
導出の最後
でのみ使う

$$\therefore L(G) = \{(ab)^n \mid n \geq 1\}$$

(問3) アルファベット $\{a, b\}$ 上の次の
2つの言語を考える.

$$L = \{a^r b^s \mid r, s > 0\}$$

$$L' = \{a^n b^n \mid n > 0\}$$

このとき、 L と L' を生成する
文法を書け.

$$L = \{ab, aab, abb, aabb, aaabbb, \dots\}$$

$$L' = \{ab, aabb, aaabbb, \dots\}$$

L' に対する文法.

$$S \rightarrow ab, \quad S \Rightarrow \underbrace{a}_m \underbrace{Sb}_n \Rightarrow \underbrace{aa}_m \underbrace{Sbb}_n$$

L に対する文法.

$$A \rightarrow aA, \quad A \rightarrow \lambda$$

$$A \Rightarrow aA \Rightarrow aaA \Rightarrow \dots \Rightarrow a^n A \Rightarrow a^n \quad (n > 0)$$

← 生成する方法

$$S \Rightarrow aA, \quad A \rightarrow aA, \quad A \rightarrow b$$

$$A \rightarrow bB, \quad B \rightarrow bB, \quad B \rightarrow b$$

(ps) 例 1.2.7

言語 $\{a^n b^n c^n \mid n > 0\}$

を生成する文脈保存文法

ex. $a^3 b^3 c^3$ の導出. ($n=3$ の場合)
$$S \rightarrow a^{\textcircled{1}} S B C \mid a^{\textcircled{2}} B C.$$
③ $CB \rightarrow BC$ ④ $aB \rightarrow ab$ ⑤ $bB \rightarrow bb$ ⑥ $bC \rightarrow bc$ ⑦ $cC \rightarrow cc$

$$S \Rightarrow a^{\textcircled{1}} S B C$$

$$\Rightarrow a^{\textcircled{1}} a^{\textcircled{1}} S B C B C$$

$$\Rightarrow a a^{\textcircled{1}} a^{\textcircled{1}} B C B C B C$$

$$\Rightarrow a a a B B C C B C$$

$$\Rightarrow a a a B B C B C C$$

$$\Rightarrow a a a B B B C C C$$

$$\Rightarrow a a a b B B C C C$$

$$\Rightarrow a a a b b B C C C$$

$$\Rightarrow a a a b b b C C C$$

$$\Rightarrow a a a b b b c C C$$

$$\Rightarrow a a a b b b c c C$$

$$\Rightarrow a a a b b b c c c$$

$$\Rightarrow a a a b b b c c c$$

$$\Rightarrow a a a b b b c c c$$

$$\Rightarrow a a a b b b c c c$$

3番目のプロダクションを

 $\frac{n(n-1)}{2}$ 回使うと $a^n (BC)^n \xrightarrow{*} a^n b^n c^n$

となる

→ 何故? (試験出る!)

文脈依存言語

 $\times \{a^n b^n c^n \mid n > 0\}$

文脈自由言語

(p20)

1.4 プログラム言語構文解析


ex. (if-then-else 構文を生成する
簡単な文法)

$S \rightarrow \text{if } C \text{ then } S \text{ else } S \mid$
 $\text{if } C \text{ then } S \mid a \mid b$
 $C \rightarrow p \mid q$

非終端記号... S (文), C (条件文)
終端記号... a, b (文), p, q (条件)
 $\text{if}, \text{then}, \text{else}$ (予約語)

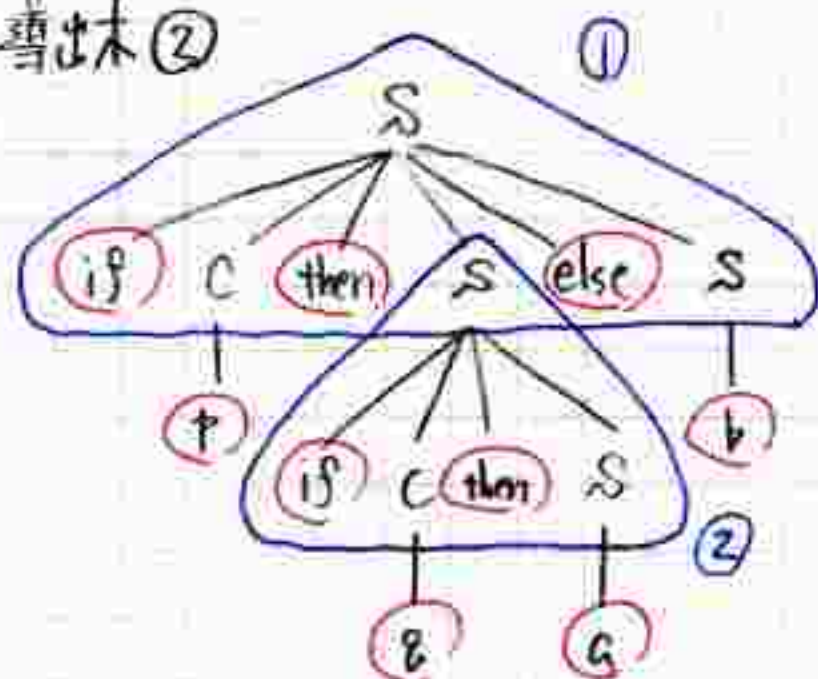
if p then if q then a else b

導出木①



(図15)

導出木②



【解釈】

① if p then (if q then a else b)

② if p then (if q then a) else b

Pascal 言語の場合、else は最も近い
then に係る。→ 導出木①が正しい文法

定義 1.4.2

文脈自由文法 G が多義的であるとは、

$L(G)$ に属するある列 x が 2 つの異なる
導出木を持つときをいう。

④ プログラム言語の構文を定義
する文法は、多義的であっては
ならない。

6/25

(p23) 文脈自由言語に対する解析問題


④ 2つの基本戦略

(1) 上昇型... 終端記号列 x に対する
(ボトムアップ) 導出木を (葉) (根)
導出木を 下から上に向けて
構成していく

(2) 下降型... (根) (葉)
(トップダウン) 上から下

- (1) $E \rightarrow E + T$
 (2) $E \rightarrow T$
 (3) $T \rightarrow T * F$
 (4) $T \rightarrow F$
 (5) $F \rightarrow (E)$
 (6) $F \rightarrow 2$
- (開始記号: E)

④ 上昇型解析の例

 $2 + 2 * 2$ $\leftarrow E + 2 * 2$ (6) と反転 $\leftarrow () + 2 * 2$ (4) と反転 $\leftarrow (E) + 2 * 2$ (2) と反転 $\leftarrow E + (F) * 2$ (6) と反転 $\leftarrow E + T * 2$ (4) と反転

この次のプロダクションを反転するか?

3つの選択肢.

どれか一つを選んでみる

 ~~$E + T \Rightarrow E$~~ ~~$T \Rightarrow E$~~ $(3) \quad 2 \Rightarrow F$

↓ バックトラック
 ↓
 ↓

 $\leftarrow E + T * F$ (6) と反転 $\leftarrow E + ()$ (3) と反転 $\leftarrow E$ (1) と反転

例 144 (下降型解析)

トップダウン解析 (根 → 葉)

 $C \rightarrow \text{begin } S_1 \text{ end}$ (複号文) $S_1 \rightarrow SS_2$ $S_2 \rightarrow : S_1 \mid \lambda$ $S \rightarrow A \mid W \mid C$ $A \rightarrow U := T$ (A文) $T \rightarrow \text{pred}(U) \mid \text{succ}(U) \mid 0$ $W \rightarrow \text{while } U \neq U \text{ do } S$ (while文) $U \rightarrow x \mid y$ (\mid は or, λ は空列) $\text{pred}(x) = x - 1$

↑

前者閉数 (ただし $x \geq 1$) $\text{succ}(x) = x + 1$

↑

後者閉数

 $\text{begin } y := 0 ;$ $\text{while } x \neq y \text{ do}$ $y := \text{succ}(y)$ end ↓ 解析する終端記号列. ($y := x$ と同じ結果になる)

実際の入力は、改行コードを含まない

 $\text{begin } y=0; \text{ while } x \neq y \text{ do } y := \text{succ}(y) \text{ end}$

$C \Rightarrow \text{begin } S_1 \text{ end}$

LL 解析の例

$\Rightarrow \text{begin } \boxed{S} S_2 \text{ end}$

$\Rightarrow \text{begin } \boxed{A} S_2 \text{ end}$

$\Rightarrow \text{begin } \boxed{U} := \boxed{T} S_2 \text{ end}$

$\Rightarrow \text{begin } \boxed{y} := \boxed{T} \boxed{S_2} \text{ end}$

$\Rightarrow \text{begin } y := \boxed{0} ; \boxed{S_1} \text{ end}$

$\Rightarrow \text{begin } y := 0 ; \boxed{S S_2} \text{ end}$

$\Rightarrow \text{begin } y := 0 ; \boxed{W} S_2 \text{ end}$

バックトラックせずに
構文解析を行う

複雑
↑

文脈依存言語 ・ 自然言語	$\rightarrow \{a^n b^n c^n \mid n > 0\}$
文脈自由言語 ・ プログラム言語	$\rightarrow \{a^n b^n \mid n > 0\}$
正則言語 ・ 幼児語 ・ ジュウシマツの歌	

$\rightarrow \{a^n b^n c^n \mid n > 0\}$

$\rightarrow \{a^n b^n \mid n > 0\}$

7/2

(p29) 1.5. 文脈自由文法と自然言語

文法規則

$$\begin{cases} S \rightarrow NP \cdot VP \\ NP \rightarrow Det \ N \mid Det \ A \ N \\ A \rightarrow Adj \ A \mid Adj \\ VP \rightarrow V_{be} \ PP \\ PP \rightarrow Prep \ NP \end{cases}$$

・ 情報検索に対する自然言語処理技術
の応用

(1) 形態素解析

(2) 構文解析

S : 文
NP : 名詞句
VP : 動詞句
Adj : 形容詞
Det : 限定詞
V : 動詞
N : 名詞
Prep : 前置詞
A : 形容詞句
PP : 前置詞句

① Chomsky の普通文法理論

脳内

普通文法

= 人間言語の系

母語の文法

誕生時

後天的
学習

パラメータ設定

辞書に相当

$$\begin{cases} V_{be} \rightarrow is / \text{are} / was / \dots \\ Det \rightarrow the / an / a \dots \\ Prep \rightarrow on / in / for \dots \\ N \rightarrow ball / table \dots \end{cases}$$

ex) パラメータの例


英語
(ヘッド前置)

the man in the park

主語
(ヘッド)

日本語
(ヘッド後置)

公園にいる男



文脈依存言語 $\{a^n b^n c^n \mid n > 0\}$
文脈自由言語 $\{a^n b^n \mid n > 0\}$
有限状態言語

(言語の複雑さ)

✓ 自然言語

✓ プログラミング言語

幼児語
鳥の歌 (ジョウシツ)

(アプリケーション)

✓ 構文解析
(コンパイラ)

文句解析
情報検索

線形有界オートマトン
→ テーリング機械
プッシュダウンオートマトン
≒ コンピュータ

有限状態受理機
(有限オートマトン)

これらやる

(文法モデル)

✓ 文脈依存文法

✓ 文脈自由文法


右線型文法
(正則文法)

これらやる

「応用オートマトン工学」

④ 有限オートマトンに基づく
アプリケーション開発を目指す

有限状態受理機
世の中の様々な機械
を指す



有限状態受理機

q_0, q_1 : 状態

0, 1 : 入力信号



初期状態
(振出し)



受理状態
(あがり)

定義 2.3.7

(決定性有限オートマトン)

入力アルファベットが X の有限状態受理機 (FSA) M とは以下の条件を満たす 4 項組 (Q, δ, q_0, F) のことである。

ただし Q は有限の状態集合

ex.) 入力記号列

001 : 受理

0011 : 拒否

$X = \{0, 1\}$

$Q = \{q_0, q_1\}$

$F = \{q_1\}$

$\delta(q_0, 0) = q_1$

$\delta(q_0, 1) = q_1$

$\delta(q_1, 0) = q_1$

$\delta(q_1, 1) = q_0$

q_0 は初期状態, $F \subseteq Q$ は受理状態の集合, δ は以下の形の状態遷移関数

$\delta(p, a) = q$

は M が状態 p のときに記号 a を読み取り、状態 q に遷移することを表す

(p37) 定義 2.1.5

$G = (X, V, S, P)$ を文法とする P の
 推移関数の形に関する制限に従って.

G は $\gamma\text{I}\gamma^i$ ($i = 0, 1, 2, 3$) と分類される

ex. $\gamma\text{I}\gamma^2$ = 相斥自由, $\gamma\text{I}\gamma^1$ = 相斥依存

(1) 文法が $\gamma\text{I}\gamma^3$ であるとは、すべての推移関数が、

$A \rightarrow aC$ または $A \rightarrow b$

なる形のときをいう。ただし $A, C \in V$,

$a, b \in X$ または $b = \lambda$ とする。この文法は、
右線形文法 と呼ばれる。→ 空列。

定義 2.3.9

有限状態自動機
 記号列の集合

入力アルファベット X の FSA $M = (Q, \delta, q_0, F)$
 によって受理される 言語 $T(M)$ は、

$T(M) = \{ \omega \mid \delta^*(q_0, \omega) \in F \}$

と定義される。

↓ δ 関数の
 有限回の適用。

命題 2.3.10

すべての FSL は右線型言語である

注) X^* の部分集合 L は どれか ある FSA
 M に対して、 $T(M)$ と等しくなるとき
有限状態言語 (FSL) であるといふ

(略証)


$$P = \{ \delta \rightarrow x\delta' \mid \delta' \in \delta(\delta, x) \}$$

$$\cup \{ \delta \rightarrow x \mid \delta(\delta, x) \in F \}$$

→ δ 推移関数とする右線型文法と
 構成可能はい。

対応する推移関数

$q_0 \rightarrow 0q_1, \quad q_0 \rightarrow 1q_1,$
 $q_1 \rightarrow 0q_1, \quad q_1 \rightarrow 1q_0,$
 $q_0 \rightarrow \lambda, \quad q_1 \rightarrow 1$



$\delta(q, x) \in F$

$\delta(q_0, \lambda) \in F \rightarrow q_0 \rightarrow \lambda$
 ↳ q_0 自身に遷移

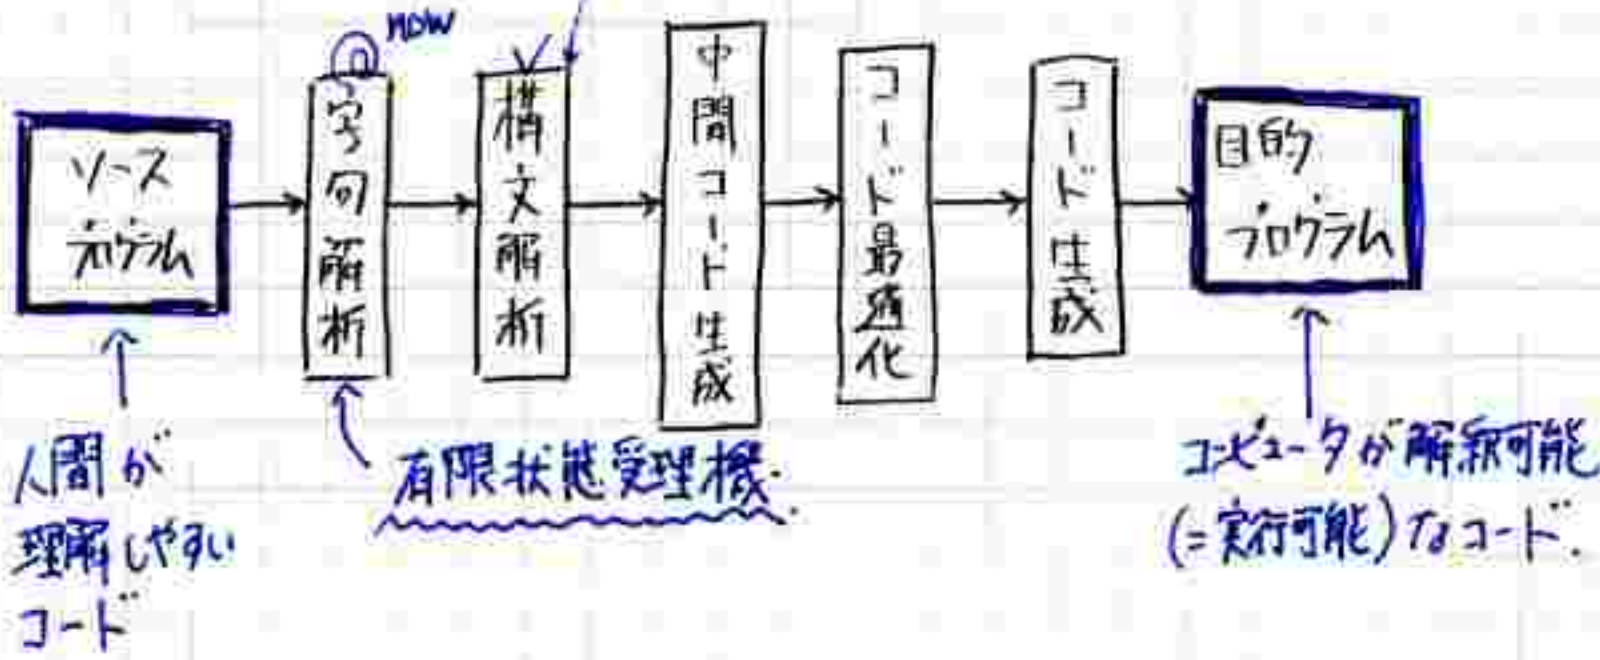
$\delta(q_1, 1) \in F \rightarrow q_0 \rightarrow 1$

ex.) $001 \in T(M)$

$q_0 \Rightarrow 0q_1 \Rightarrow 00q_1 \Rightarrow 001 //$


コンパイラの構成

文脈自由文法



① 文句解析に用いられる有限状態受理機 (FSA)

① キーワードを受理する FSA



② 識別子 (identifier)




ex.) uec 2011

問1.) a と b を入力記号とする。
a と偶数個含む a と b の
記号列のみ受理する FSA を構成せよ。

ex.) aababbab 4つ } 受理
aa 2つ
bbb (aは0個)
ababaa 4つ


ababa 3
bbabb 1
 等は受理
 しない



ex.)

受理 正しい記号列 ababa
2桁


A.



問3) λ 記号として, a と b を与え
 a と b の記号列で a の個数が偶数個で b の個数が 3 で割れるもののみを受理する FSA を構成せよ.

受理排列記号列 $ababaa$

A.



a. ... 偶数個 読まれるのは、 a が
必ず 上で 終わると言

b. ... b は 上下に 依らないが 必ず
3回 読まれるわけではない